

Relatório da Análise e Preparação dos Dados

Integrantes: Analice Coimbra Carneiro, Mariah Alice Pimentel, Sofia Botechia Hernandez, Victória Duarte
Professor orientador: Eduardo Savino | **Projeto 10:** Grupo Nour - 4CCOMP Noturno

1. Identificação das Fontes de Dados

Os dados utilizados neste projeto são provenientes da base fornecida pela parceira CTI Global. O arquivo recebido, denominado “*Demonstrativo Fecap v3.csv*”, contém dados financeiros projetados para uma empresa concessionária ao longo de 12 anos em 1.200 cenários distintos, baseados em projeções futuras a partir do ano de 2027.

- Formato: CSV (delimitador ";")
- Codificação: ISO-8859-1 (Latin-1)
- Volume: 1.002.000 linhas (além do cabeçalho).
- Padrão Numérico: Padrão brasileiro (separador de milhar "." e decimal ",").
- Cabeçalho: O arquivo bruto original não possui cabeçalho, exigindo inferência e nomeação de colunas no momento da ingestão (Cenário, Ano, Conta, Valor).

2. Descrição e Exploração Inicial dos Dados (Profiling)

A etapa de perfilamento (RF03) foi conduzida via notebook (Colab) para compreender a estrutura, distribuições e inconsistências presentes no arquivo bruto.

Característica	Observação Encontrada
Valores Ausentes	Foi identificada a presença de linhas de "conta vazia" e metadados por cenário/ano que não possuem valores numéricos válidos.
Anomalias / Outliers	O Ano 12 apresenta efeitos de liquidação da concessão, o que gera valores que destoam significativamente (outliers esperados) da tendência dos Anos 1 a 11.
Privacidade	Os dados já foram previamente anonimizados pela CTI. Não há dados sensíveis de clientes (LGPD), impossibilitando também o cálculo real de métricas como CAC e LTV, as quais serão simuladas.

3. Seleção, Limpeza e Uniformização

Para estruturar os dados de forma adequada às análises financeiras e de regressão subsequentes (RF04), aplicou-se o seguinte fluxo de tratamento:

1. Seleção: Foram mantidas apenas as linhas que representam contas contábeis válidas (Ativo, Passivo, Receitas, Custos), removendo ruídos e linhas em branco.
2. Limpeza: Valores ausentes (NaN) nas colunas de valor financeiro foram preenchidos com 0.00 ou removidos, dependendo da natureza da conta, para evitar distorções estatísticas.
3. Uniformização:
 - Conversão de tipos de dados: A coluna que designava o período (ex: "Ano 1") teve seu texto extraído, convertendo-a para uma variável numérica inteira (1, 2, 3...) para facilitar análises temporais e regressões.
 - Normalização de strings: Nomes de contas contábeis padronizados (sem acentos e em caixa alta) para facilitar os agrupamentos.

4. Derivação, Integração e Formatação

A base passou de um formato longo (long format) para um formato largo (wide format) através de pivotamento, em que cada conta contábil passou a ser uma coluna. Isso viabiliza o cálculo linha a linha dos indicadores do negócio.

- Derivação de Variáveis: Foram criados novos campos calculados como a *Margem* (Receita - Custos Variáveis) e *Margem Percentual*.
- Formatação Final: Os valores financeiros foram padronizados para numéricos de ponto flutuante com duas casas decimais. As bases transicionais foram salvas em formato Parquet (camadas staging e processed) para otimizar o tempo de leitura e desempenho do futuro dashboard.

5. Análise Descritiva Preliminar

A partir da base formatada, o comportamento geral dos dados pôde ser resumido por medidas de posição (média, mediana) e dispersão (desvio padrão) por conta. Gráficos de dispersão e boxplots evidenciaram a estabilidade das projeções nos anos iniciais e os picos de liquidação no último período (Ano 12), o qual exigirá isolamento nas modelagens de regressão futuras.